

# 引入死区迟滞的低轨卫星编队分布式深度强化学习避障控制

王 昱<sup>1</sup>, 王荣辉<sup>1</sup>, 严 晗<sup>2,3</sup>, 胡银龙<sup>1</sup>, 蔡 旭<sup>1</sup>, 袁 利<sup>3,4</sup>

(1. 河海大学人工智能与自动化学院, 常州 213200; 2. 北京控制工程研究所, 北京 100094;  
3. 空间智能控制技术全国重点实验室, 北京 100094; 4. 中国空间技术研究院, 北京 100094)

**摘 要:** 针对低轨卫星编队在强摄动与空间碎片威胁下的避障与燃料优化控制问题, 以及现有深度强化学习方法在驻留期固有的稳态推力残余问题, 提出一种引入死区迟滞的低轨卫星编队分布式深度强化学习避障控制方法。首先, 建立考虑  $J_2$  摄动与大气阻力的相对动力学模型, 在此基础上, 以柔性演员-评论家 (SAC) 算法为核心构建分层分布式控制框架。策略网络输出期望边界条件, 经 3 次 Hermite 插值与比例-微分 (PD) 控制器跟踪生成连续平滑推力; 同时, 将底层实际推力以动力学惩罚形式反馈, 引导卫星低速趋近目标区域。进一步设计基于位置-速度联合判据的相空间死区迟滞机制, 当卫星状态收敛至稳态收敛域时, 物理截断推力并暂停网络推理, 显著降低全任务周期燃料消耗。仿真结果表明, 所提方法在 100 次蒙特卡罗评估中编队成功率达 87%, 燃料消耗较 PPO 基线降低约 33%; 策略可零样本迁移至不同集群规模、目标区域、执行噪声与碎片数量等场景, 泛化成功率维持在 72% 以上。

**关键词:** 低轨卫星编队; 深度强化学习; 分布式控制; 相空间死区迟滞; 避障控制

中图分类号: V448.2; TP18

文献标识码: A

文章编号:

## Distributed Deep Reinforcement Learning-Based Obstacle Avoidance Control for LEO Satellite Formations with Deadband Hysteresis

WANG Yu<sup>1</sup>, WANG Ronghui<sup>1</sup>, YAN Han<sup>2,3</sup>, HU Yinlong<sup>1</sup>, CAI Xu<sup>1</sup>, YUAN Li<sup>3,4</sup>

(1. College of Artificial Intelligence and Automation, Hohai University, Changzhou 213200, China; 2. Beijing Institute of Control Engineering, Beijing 100094, China; 3. National Key Laboratory of Space Intelligent Control, Beijing 100094, China; 4. China Academy of Space Technology, Beijing 100094, China)

**Abstract:** To address obstacle avoidance and fuel optimization for LEO satellite formations under strong perturbations and space debris threats, alongside the steady-state residual thrust issue of existing deep reinforcement learning (DRL) methods during station-keeping, a distributed DRL method with deadband hysteresis is proposed. First, a relative dynamics model considering  $J_2$  perturbation and atmospheric drag is established, based on which a hierarchical distributed control framework centered on the soft actor-critic (SAC) algorithm is constructed. The policy network outputs desired boundary conditions, tracked by cubic Hermite interpolation and a proportional-derivative (PD) controller to generate continuous smooth thrust. Simultaneously, actual low-level thrust is fed back as a dynamic penalty, guiding satellites to approach the target at low speed. Furthermore, a phase-space deadband hysteresis mechanism using a joint position-velocity criterion is designed. It physically truncates thrust and suspends network inference upon converging to the steady-state region, significantly reducing total fuel consumption. In 100 Monte Carlo trials, the proposed method achieves an 87% formation success rate, reducing fuel consumption by approximately 33% compared to the PPO baseline. The policy enables zero-shot transfer across varying swarm sizes, target regions, actuation noises, and debris numbers, maintaining a generalization success rate above 72%.

**Key words:** LEO satellite formation; Deep reinforcement learning; Distributed control; Phase-space deadband hysteresis; Obstacle avoidance control

收稿日期: 2026-05-21;

修回日期: 2026-06-27

基金项目: 国家自然科学基金 (U21B6001); 江苏省基础研究计划 (BK20250120, BK20240349); 中央高校基本科研业务费专项资金 (B250201088); 常州市科技计划应用基础研究专项 (CJ20250106)

## 0 引言

近年来,以“星链”为代表的巨型星座加速部署,推动地球低轨在轨航天器数量快速增长,致使空间碎片碰撞风险日益突出<sup>[1]</sup>。在此背景下,微小卫星编队凭借成本低、冗余度高、灵活性强等优势,在分布式观测、大型结构在轨组装及碎片清除等任务中受到广泛关注<sup>[2-3]</sup>。TechSat 21 与 CanX-4/5 等任务<sup>[4-5]</sup>验证了多星协同飞行与相对位置保持的可行性。然而, $J_2$ 摄动引起的长期构型漂移以及日益密集的空间碎片,显著增加了编队控制的难度。考虑到微小卫星携带的燃料极为有限<sup>[6]</sup>,如何在保障避障安全与构型稳定的前提下实现燃料消耗的最优控制,已成为当前编队控制的核心难题。

针对低轨卫星编队控制问题,现有研究主要分为两类:基于优化的规划方法与基于反馈的跟踪控制方法。在优化规划方面,Morgan 等<sup>[7]</sup>基于序列凸优化提出了面向大规模集群重构的分散化模型预测控制算法,可以在 $J_2$ 摄动环境下求解无碰撞轨迹;Basu 等<sup>[8]</sup>通过凸松弛方法进一步降低了摄动环境下集群无碰撞轨迹规划的计算复杂度;Bashnick 等<sup>[9]</sup>提出了障碍物环境下的快速模型预测控制算法。在跟踪控制方面,Wang 等<sup>[10]</sup>针对航天器近距离操作任务,提出了预定义时间六自由度跟踪控制方法。然而,前者在编队规模扩大或环境突变时实时性受限,后者难以同时满足多重避障约束与燃料优化需求。整体而言,传统方法对复杂低轨场景的适应性仍显不足。

深度强化学习(Deep reinforcement learning, DRL)通过智能体与环境的交互自主学习控制策略,近年来已在航天器控制领域得到初步应用<sup>[11]</sup>。在轨道机动方面,Hovell 等<sup>[12]</sup>提出了基于 DRL 的航天器近距离操作制导方法;Tafanidis 等<sup>[13]</sup>采用柔性演员-评论家(Soft actor-critic, SAC)算法实现了卫星低轨轨道保持。在安全避障方面,Mu 等<sup>[14]</sup>基于 DRL 实现了航天器在多碎片场景下的自主避碰,Qu 等<sup>[15]</sup>进一步将 DRL 应用于交会过程的安全接近制导。在编队控制与燃料优化方面,徐龙威等<sup>[16]</sup>基于 SAC 算法实现了燃料最优的编队重构控制;Sun 等<sup>[17]</sup>基于强化学习实现了集群重构中的分布式协同控制;金伟

成等<sup>[18]</sup>进一步将底层控制器的燃料消耗以负奖励形式反馈至策略网络,使所学策略兼具轨迹的动力学可行性;Jin 等<sup>[19]</sup>将 DRL 与 SE(3)动力学相结合,实现了可扩展至不同集群规模的分布式编队控制。上述编队工作多聚焦于趋近与重构阶段。

然而,将连续动作 DRL 策略直接应用于长时间驻留控制时,仍存在两个主要问题:其一是稳态推力残余问题。由于连续动作策略难以输出绝对零值,卫星在目标区域内仍持续产生残余推力,导致驻留期燃料无谓消耗。虽然引入正则化项可抑制动作的高频分量<sup>[20]</sup>,但仅能降低振荡幅值,无法实现物理层面的推力归零;此外,传统模型预测控制中虽已应用死区机制节省燃料<sup>[21]</sup>,但连续动作 DRL 控制仍缺乏相应的物理截断机制。其二是推力指令跳变问题。若策略网络直接输出底层推力指令,离散决策步之间容易出现指令跳变,导致执行器超调与高频反向点火,进而加剧燃料浪费并威胁执行机构寿命。采用参数化高层动作虽可改善轨迹连续性<sup>[22]</sup>,但决策层与执行层之间仍缺乏兼顾指令平滑过渡与物理可实现性的有效衔接机制。

针对上述两类核心问题,本文提出一种引入死区迟滞的低轨卫星编队分布式深度强化学习避障控制方法。主要贡献包括:1) 构建基于 SAC 的分层分布式控制框架。策略网络输出期望边界条件,经 3 次 Hermite 插值与比例-微分(Proportional-derivative, PD)控制器跟踪生成连续平滑推力,消除决策步间的指令跳变,并将底层实际推力以惩罚形式反馈至奖励函数,引导策略主动优化真实的燃料消耗。2) 设计相空间死区迟滞机制。基于位置-速度联合判据,在稳态收敛域内物理截断推力并暂停网络推理,该机制与动力学惩罚协同作用,降低全任务周期燃料消耗,有效克服连续动作策略在驻留期的残余推力问题。

## 1 问题描述

### 1.1 编队飞行任务描述

本文研究一组同构微小卫星在地球低轨环境下的分布式编队飞行问题。在低轨运行期间, $J_2$ 摄动会引发编队构型的持续漂移,且随机分布的非合作空间碎片对卫星构成了严重的碰撞威胁。鉴于微小卫星推力受限且携带燃料极其有限,控制策略必须

在保障飞行安全的前提下,实现燃料消耗的最优控制。为此,本文采用完全分布式架构,各卫星仅依赖星载传感器获取的局部观测信息进行独立决策;该架构解耦了对星间实时通信的依赖,使得单一训练策略能够直接适应不同规模的卫星集群。在此场景下,各卫星需由随机初始位置出发,安全穿越碎片群并最终全员进入指定目标区域稳态驻留。

## 1.2 $J_2$ 摄动相对动力学模型

微小卫星编队控制的核心在于维持星间的相对运动状态。为此,本文采用局部垂直-局部水平坐标系(LVLH)描述卫星的相对运动,并以地心惯性坐标系(ECI)作为绝对运动与摄动计算的物理基准。由于采用分布式架构、集群中不设物理领导者,LVLH系的原点 $O$ 取为沿指定参考圆轨道运行的虚拟主星质心; $X$ 轴沿径向由地心指向外, $Y$ 轴由右手定则确定,沿轨道切向, $Z$ 轴沿参考轨道面法向。两坐标系的几何空间关系如图1所示。




图1 地心惯性坐标系与编队坐标系示意图

Fig. 1 Schematic of the Earth-centered inertial frame and the LVLH formation frame

记第 $j$ 颗卫星在LVLH系下的相对位置为 $\mathbf{r}_j = [x_j, y_j, z_j]^T$ , 相对速度为 $\mathbf{v}_j = [\dot{x}_j, \dot{y}_j, \dot{z}_j]^T$ 。在忽略三体引力等高阶摄动的基础上,保留主导低轨构型漂移的 $J_2$ 摄动项,并将差分大气阻力作为环境扰动计入,卫星相对参考轨道的运动可由附加了差分 $J_2$ 加速度的标准Clohessy-Wiltshire (CW)方程<sup>[23]</sup>描述:

$$\begin{cases} \ddot{x}_j = 3n^2 x_j + 2n\dot{y}_j + u_{jx} + \Delta a_{J_2,x} + \Delta a_{D,x} \\ \ddot{y}_j = -2n\dot{x}_j + u_{jy} + \Delta a_{J_2,y} + \Delta a_{D,y} \\ \ddot{z}_j = -n^2 z_j + u_{jz} + \Delta a_{J_2,z} + \Delta a_{D,z} \end{cases} \quad (1)$$

式中:  $n = \sqrt{\mu/a_{\text{ref}}^3}$  为参考圆轨道的平均角速度,其中 $\mu$ 为地球引力参数,  $a_{\text{ref}} = R_e + h_{\text{ref}}$  为参考轨道半长轴,  $R_e$  为地球平均半径,  $h_{\text{ref}}$  为参考轨道高度;  $u_{jx}$ ,  $u_{jy}$ ,  $u_{jz}$  为第 $j$ 颗卫星控制加速度在LVLH三轴上的分量;  $\Delta a_{J_2,x}$ ,  $\Delta a_{J_2,y}$ ,  $\Delta a_{J_2,z}$  为差分 $J_2$ 加速度在三轴上的分量;  $\Delta a_{D,x}$ ,  $\Delta a_{D,y}$ ,  $\Delta a_{D,z}$  为差分大气阻力加速度在三轴上的分量。

为便于统一表示,引入下标 $\xi \in \{X, Y, Z\}$ 标记ECI系的三个坐标轴。给定ECI系下的位置矢量 $\mathbf{r}$ ,  $J_2$ 摄动加速度在 $\xi$ 轴上的分量为:

$$a_{J_2,\xi}(\mathbf{r}) = \frac{k_{J_2}}{r^5} r_\xi^2 \left( \frac{5z^2}{r^2} - c_\xi \right) \quad (2)$$

式中:  $k_{J_2} = \frac{3}{2} J_2 \mu R_e^2$ ,  $J_2 = 1.0826 \times 10^{-3}$  为扁率常数;

$r = \|\mathbf{r}\|$  为位置矢量的模;  $r_\xi$  为矢量 $\mathbf{r}$ 在ECI系 $\xi$ 轴上的分量;  $z$  为 $\mathbf{r}$ 在ECI系极 $Z$ 轴上的分量; 系数 $c_\xi$ 在不同轴上取值不同,  $c_X = c_Y = 1$ ,  $c_Z = 3$ 。

基于式(2),差分 $J_2$ 加速度定义为第 $j$ 颗卫星实际位置处与参考点处 $J_2$ 加速度之差<sup>[24]</sup>:

$$\Delta a_{J_2,\xi} = a_{J_2,\xi}(\mathbf{r}_{\text{abs},j}) - a_{J_2,\xi}(\mathbf{r}_{\text{ref}}) \quad (3)$$

式中:  $\mathbf{r}_{\text{ref}}$  为参考点在ECI系下的位置矢量,其模等于轨道半径 $a_{\text{ref}}$ 。在编队相对距离远小于轨道半径的条件下,即 $\|\mathbf{r}_j\| \ll a_{\text{ref}}$ ,卫星与参考点的LVLH标架近似平行,故可在LVLH系内直接构造差分摄动:将第 $j$ 颗卫星的绝对位置沿三轴取为 $a_{\text{ref}} + x_j$ ,  $y_j$ ,  $z_j$ ,代入式(2)与参考点处作差,即得式(1)中的 $\Delta a_{J_2,x}$ ,  $\Delta a_{J_2,y}$ ,  $\Delta a_{J_2,z}$ 。由式(1)~(3),建立了含差分 $J_2$ 摄动与大气阻力的卫星编队相对动力学模型,为后续控制框架设计提供动力学基础。

此外,因卫星搭载的微推力器存在物理饱和限制,所以记控制器生成的理想控制加速度为 $\mathbf{u}_{c,j}$ ,饱

和上限为  $u_{\max}$ ，则实际作用于动力学模型中的控制加速度  $u_j$  为：

$$u_j = \text{sat}_{u_{\max}}(u_{c,j}) = \begin{cases} u_{c,j}, & \|u_{c,j}\| \leq u_{\max} \\ u_{\max} \frac{u_{c,j}}{\|u_{c,j}\|}, & \|u_{c,j}\| > u_{\max} \end{cases} \quad (4)$$

即  $u_{c,j}$  在饱和范围内时直接输出，超出饱和上限时保持方向不变、按比例截断至  $u_{\max}$ 。

### 1.3 强化学习问题建模

基于 1.2 节建立的相对动力学模型，本节先给出编队控制问题的形式化描述，再在此基础上建立强化学习问题模型。由式(1)可知，第  $j$  颗卫星的运动状态可由相对位置  $r_j = [x_j, y_j, z_j]^T$  与相对速度  $v_j = [\dot{x}_j, \dot{y}_j, \dot{z}_j]^T$  共同描述，控制输入为经式(4)饱和约束的控制加速度  $u_j$ 。在此基础上，编队控制问题可表述为：为每颗卫星设计仅依赖局部观测的分布式控制律  $u_j$ ，驱动其由随机初始状态出发，在满足防碰避障约束的前提下自主安全穿越碎片群，最终全员收敛至目标区域内实现稳态驻留；其中防碰避障约束指各卫星彼此之间、卫星与空间碎片之间均须保持安全间距，且不越出任务空域边界。在此前提下，控制目标为最小化全任务周期内的综合燃料消耗：

$$J_{\text{fuel}} = \sum_{j=1}^N \int_0^T \|u_j(t)\| dt \quad (5)$$

式中： $N$  为编队卫星总数； $T$  为任务时域。

由于上述控制问题包含多重避障约束与燃料代价，且需在无星间通信、仅依赖局部观测的条件下分布式求解，难以通过传统优化方法在线处理。为此，本文将建模为部分可观测马尔可夫博弈过程。在这个框架下，每个智能体在  $t$  时刻获得局部观测  $o_j^t$ ，依据策略  $\pi$  选择动作  $a_j^t$ ，环境转移至新状态并返回即时奖励  $r_j^t$ 。智能体的目标是最大化期望累积折扣奖励<sup>[25]</sup>，其目标函数可表示为：

$$J(\pi) = E \left( \sum_{t=0}^T \gamma^t r_j^t \right) \quad (6)$$

式中： $\gamma \in (0,1]$  为折扣因子，考虑到策略需适应不同规模集群且执行期不依赖通信，本文采用集中训练、分布式执行的参数共享架构。

## 2 分层分布式编队控制框架设计




图 2 分层分布式编队控制框架

Fig. 2 Hierarchical distributed formation control framework

本文所提控制框架的整体结构如图 2 所示，自上而下分为 3 个层次，分别承担环境交互、上层决策和底层执行的功能。

环境层基于  $J_2$  摄动相对动力学模型，模拟卫星在低轨环境下的真实运动，并为每颗卫星提供局部观测与即时奖励。决策层采用 SAC 算法训练策略网络，该网络以局部观测作为输入，输出下一决策周期的期望位置与速度增量。所有卫星共享一套网络参数，确保分布式自主决策能力，并避免了对实时星间通信的依赖。执行层负责将决策层的离散期望状态转化为连续平滑的物理推力指令，具体通过 3 次 Hermite 插值生成参考轨迹，再由 PD 跟踪器计算控制力。此外，推力指令在送入推力器前，会经过相空间死区迟滞模块：当卫星状态收敛至稳态收敛域时，推力输出将被物理截断为零，同时暂停网络前向推理；反之，则按计算值正常执行。

### 2.1 决策层设计

决策层负责将每颗卫星的局部观测映射为下一决策周期内的运动指令。本节分别介绍局部观测、动作、参数共享架构与策略训练方式。

第  $j$  颗卫星的局部观测向量  $o_j$  由 4 部分拼接而成：归一化位置  $\hat{r}_j$ 、归一化速度  $\hat{v}_j$ 、目标区域编码  $e_{\text{zone},j}$  以及球面雷达测距  $\hat{l}_j$ ：

$$\mathbf{o}_j = [\hat{\mathbf{r}}_j^T, \hat{\mathbf{v}}_j^T, \mathbf{e}_{\text{zone},j}^T, \hat{\mathbf{l}}_j^T]^T \quad (7)$$

式中:  $\hat{\mathbf{r}}_j = \mathbf{r}_j / r_{\text{scale}}$ ,  $\hat{\mathbf{v}}_j = \mathbf{v}_j / v_{\text{scale}}$ , 分别由第  $j$  颗卫星的相对位置与相对速度除以特征量纲得到, 用于将数值压缩至适合网络处理的区间; 目标区域编码  $\mathbf{e}_{\text{zone},j}$  的各分量反映卫星当前位置相对于目标区域各轴边界的归一化偏移, 用于向策略网络提供目标方位信息; 球面雷达测距  $\hat{\mathbf{l}}_j$  由沿 Fibonacci 球面均匀分布的  $N_{\text{ray}} = 32$  个方向上的探测距离归一化得到, 其第  $k$  个分量  $\hat{l}_{j,k}$  的计算公式为:

$$\hat{l}_{j,k} = \max\left(1 - \frac{d_k}{R_{\text{obs}}}, 0\right) \quad (8)$$

式中:  $d_k$  为该方向上探测到的最近障碍物距离;  $R_{\text{obs}}$  为雷达最大探测半径。分量取值越接近 1 表示该方向障碍物极近, 取值为 0 表示安全。

为避免策略网络直接输出底层推力时相邻决策步间的指令跳变与精细分配负担, 本文将 Actor 网络的动作设计为高层运动意图, 即下一决策周期内的期望位置增量与期望末速度:

$$\mathbf{a}_t = [\Delta \mathbf{r}_d^T, \mathbf{v}_d^T]^T \quad (9)$$

式中:  $\Delta \mathbf{r}_d$  与  $\mathbf{v}_d$  共同构成了卫星在下一决策周期结束时的期望相对状态, 作为 2.2 节底层轨迹执行的边界条件; 策略网络由此只需规划中长期运动意图, 轨迹平滑生成与推力分配交由执行层承担。




图 3 决策层分布式策略网络架构

Fig. 3 Architecture of the decentralized policy network in the decision layer

## 2.2 底层轨迹执行

决策层每隔决策周期  $T_n$  输出新的期望状态, 若底层控制器直接将此跳变信号作为跟踪目标, 会引发推力器的剧烈超调与高频反向点火。为此, 系统

本文采用参数共享的分布式架构, 所有卫星共享同一组策略与价值网络参数。训练阶段, 各卫星的交互数据统一汇入回放缓冲区进行集中优化; 而在执行阶段, 每颗卫星仅依靠自身局部观测独立完成前向推理, 从而实现完全自主的分布式决策。

策略网络采用 SAC 算法<sup>[26]</sup>进行训练。相较于近端策略优化 (Proximal policy optimization, PPO) 等在线策略梯度方法, SAC 通过经验回放实现离线更新, 样本利用效率更高; 同时引入最大熵正则化鼓励探索, 有利于应对连续动作空间与稀疏奖励并存的训练难题。其优化目标为:

$$J(\pi) = \sum_{t=0}^T \mathbb{E} \left( r(s_t, a_t) - \alpha \ln \pi(a_t | s_t) \right) \quad (10)$$

式中:  $s_t$ ,  $a_t$  分别为  $t$  时刻单颗卫星的局部观测与动作;  $r(s_t, a_t)$  为对应的即时奖励;  $\alpha$  为温度系数, 用于调节奖励项与熵项的相对权重。Critic 网络  $Q_\theta$  通过最小化时序差分误差更新:

$$L_Q(\theta) = \mathbb{E} \left( \frac{1}{2} (Q_\theta(s, a) - r - \gamma V(s'))^2 \right) \quad (11)$$

式中:  $V(s')$  为下一状态的价值估计。Actor 网络  $\pi_\phi$  通过最小化以下损失函数更新:

$$L_\pi(\phi) = \mathbb{E} \left( \alpha \ln \pi_\phi(a | s) - Q_\theta(s, a) \right) \quad (12)$$

整体网络架构如图 3 所示。

先由期望状态重构连续参考轨迹, 再交由 PD 控制器生成实际推力。

在任意决策周期初始时刻, 以卫星当前的实际位置与速度  $(\mathbf{r}_0, \mathbf{v}_0)$  作为轨迹起点, Actor 网络输出的



期望位置增量  $\Delta \mathbf{r}_d$  与期望末速度  $\mathbf{v}_d$  经线性映射后的轨迹终点为：

$$\mathbf{r}_1 = \mathbf{r}_0 + \Delta \mathbf{r}_d, \quad \mathbf{v}_1 = \mathbf{v}_d \quad (13)$$

以  $(\mathbf{r}_0, \mathbf{v}_0)$  和  $(\mathbf{r}_1, \mathbf{v}_1)$  为边界条件，采用 3 次 Hermite 插值构造参考轨迹：

$$\mathbf{r}_{\text{ref}}(\sigma) = H_{00}(\sigma)\mathbf{r}_0 + H_{10}(\sigma)T_{\text{fl}}\mathbf{v}_0 + H_{01}(\sigma)\mathbf{r}_1 + H_{11}(\sigma)T_{\text{fl}}\mathbf{v}_1 \quad (14)$$

式中： $\sigma \in [0, 1]$  为归一化时间， $\sigma = (t - t_0) / T_{\text{fl}}$ ， $t_0$  为当前决策周期的起始时刻； $H_{00}$ ， $H_{10}$ ， $H_{01}$ ， $H_{11}$  为标准 3 次 Hermite 基函数：

$$\begin{aligned} H_{00}(\sigma) &= 2\sigma^3 - 3\sigma^2 + 1, & H_{10}(\sigma) &= \sigma^3 - 2\sigma^2 + \sigma \\ H_{01}(\sigma) &= -2\sigma^3 + 3\sigma^2, & H_{11}(\sigma) &= \sigma^3 - \sigma^2 \end{aligned} \quad (15)$$

上述基函数确保了轨迹在各个决策周期边界处的位置与速度均保持连续，从而避免了决策节点处的速度跳变。对式(14)关于时间求导，可得参考速度：

$$\mathbf{v}_{\text{ref}}(t) = \frac{1}{T_{\text{fl}}} \frac{d\mathbf{r}_{\text{ref}}}{d\sigma} \quad (16)$$

基于构建好的参考轨迹，底层由 PD 控制器实时计算控制加速度：

$$\mathbf{u}_c(t) = -k_p(\mathbf{r}(t) - \mathbf{r}_{\text{ref}}(t)) - k_d(\mathbf{v}(t) - \mathbf{v}_{\text{ref}}(t)) \quad (17)$$

式中： $\mathbf{r}(t)$ ， $\mathbf{v}(t)$  为第  $j$  颗卫星的实际位置与速度； $k_p$ ， $k_d$  分别为比例增益和微分增益。最终，计算所得的  $\mathbf{u}_c(t)$  经受推力器物理饱和限幅处理，才作为有效推力作用于卫星动力学系统。

### 2.3 相空间死区迟滞机制

针对上述稳态残余推力与冗余推理问题，本文在推力指令送入推力器之前引入一层相空间死区迟滞切换机制：当卫星状态收敛至稳态收敛域后，推力直接被截断为零、策略网络暂停推理；一旦状态重新偏离稳态收敛域，系统自动恢复控制。该机制的示意如图 4 所示。

死区的触发需要综合评估空间与速度偏离度，因此定义相空间误差：

$$\gamma_j(t) = w_p \cdot e_{p,j}(t) + w_v \cdot e_{v,j}(t) \quad (18)$$

式中： $e_{p,j}(t)$  为至目标区域边界的距离，区域内为 0； $e_{v,j}(t) = \|\mathbf{v}_j(t)\|$  为卫星速度范数； $w_p$ ， $w_v$  分别为位

置和速度两项的加权系数，使两类误差在数值上处于同一量级。 $\gamma_j$  的数值直观映射了卫星偏离理想静止态的程度。




图 4 相空间死区迟滞切换逻辑

Fig. 4 Phase-space deadband hysteresis switching logic

如果仅依托单一阈值判定休眠，微小的环境扰动将迫使系统在启停模式间陷入高频振荡，即 Zeno 现象<sup>[27]</sup>。为抑制此类边界振荡，采用进入阈值  $\epsilon_{\text{enter}}$  与退出阈值  $\epsilon_{\text{exit}}$  构成如下切换逻辑：

1) 进入死区（推力截断，网络休眠）：当  $\gamma_j(t) \leq \epsilon_{\text{enter}}$  且卫星在目标区域内且最小星间距  $d_{\min} \geq d_{\text{safe}}^{\text{in}}$  时，系统才能进入休眠。

2) 退出死区（网络唤醒，恢复控制）：当  $\gamma_j(t) > \epsilon_{\text{exit}}$  或卫星离开目标区域或  $d_{\min} < d_{\text{safe}}^{\text{out}}$  时，系统脱离死区控制。

定义  $d_{\min} = \min_{i \neq j} \|\mathbf{r}_j - \mathbf{r}_i\|$  为第  $j$  颗卫星与编队内最近卫星的欧氏距离； $d_{\text{safe}}^{\text{in}}$ ， $d_{\text{safe}}^{\text{out}}$  分别为星间安全间距的进入阈值与退出阈值。

相空间误差的迟滞区  $[\epsilon_{\text{enter}}, \epsilon_{\text{exit}}]$  确保卫星退出死区后须将误差显著降低方可再次进入，星间距的迟滞门限则抑制了邻近卫星动态进出安全范围引发的反复切换，两者共同避免了高频振荡。此外，当  $J_2$  摄动漂移使卫星状态偏离收敛域时，系统自动唤醒网络恢复控制，保证编队在驻留中的稳定性。

### 2.4 奖励函数设计

单步奖励由碰撞惩罚、导航与驻留奖励、动力学惩罚 3 项组成：

$$r_{\text{total}} = r_{\text{col}} + r_{\text{d}} + r_{\text{dyn}} \quad (19)$$

式中：碰撞惩罚  $r_{\text{col}}$  为发生越界、碎片碰撞或星间碰撞时提供的较大负奖励，用于保证安全性；导航与驻留奖励  $r_d$  用于引导卫星向目标区域收敛。在目标区域外， $r_d$  采用基于距离递减的进度奖励形式：

$$r_d = r_{\text{base}} + r_{\text{inc}} \cdot (e_{p,j}(t-1) - e_{p,j}(t)) \quad (20)$$

式中： $r_{\text{base}}$  为基础负奖励； $r_{\text{inc}}$  为进度奖励系数； $e_{p,j}(t)$  为当前步卫星至目标区域边界的距离。当卫星靠近目标区域时  $e_{p,j}$  减小，奖励为正，反之为负，这种逐步反馈能够缓解稀疏奖励下的训练困难。卫星进入目标区域后， $r_d$  切换为固定的正奖励  $r_{\text{dwell}}$ ，鼓励卫星稳定驻留。此外，当全部卫星满足编队成功判据时，在任务终止时刻对每颗卫星额外给予一次性终局奖励  $r_{\text{success}}$ ，该项仅在终止步叠加，不计入单步即时奖励。

动力学惩罚  $r_{\text{dyn}}$  在降低燃料消耗中起核心作用，如果在策略层仅对网络输出的期望位置和速度做惩罚，很难真实反映底层推力器的物理消耗。因此，本文直接将每个决策周期内底层 PD 跟踪器实际产生的推力提取出来，作为惩罚项反馈给策略网络：

$$r_{\text{dyn}} = -w_{\text{dyn}} \cdot \frac{1}{K} \sum_{k=1}^K \frac{\|u_k\|_2}{u_{\text{max}}} \quad (21)$$

式中： $u_k$  为第  $k$  步 PD 跟踪输出经饱和后的实际推力； $K$  为单个决策周期内的底层积分步数； $u_{\text{max}}$  为推力器饱和上限，用于将推力幅值归一化至  $[0,1]$  区间； $w_{\text{dyn}}$  为动力学惩罚的权重系数。该惩罚促使策略输出幅值较小的控制指令，使卫星以较低速度趋近目标区域；低速到达边界时相空间误差  $\gamma_j$  的速度项  $e_{v,j}$  较小，系统更易满足死区触发条件，从而与死区迟滞机制形成趋近—截断的协同。

## 2.5 稳定性分析

2.3 节引入的死区迟滞机制，使编队闭环系统在控制模态即网络唤醒、PD 跟踪与截断物理推力至零的休眠模态之间切换。本节分析并证明该切换系统不产生 Zeno 高频抖振、且驻留误差保持有界。分析中将策略网络输出的期望边界条件视为有界外部参考输入，聚焦于死区迟滞切换层与底层执行层。由于编队相对基线远小于轨道半径且微推力器受饱和约束，差分  $J_2$  与大气阻力构成的摄动加速度在工作

空域内有界，记为  $\|a_{d,j}\| \leq \bar{a}$ ；控制加速度满足  $\|u_j\| \leq u_{\text{max}}$ ，收敛域邻域内的速度满足  $\|v_j\| \leq v_{\text{max}}$ ，其中  $v_{\text{max}}$  为控制模态下卫星相对速度的工程上界；且设摄动上界  $\bar{a}$  足够小，使控制模态下的稳态残差界小于进入阈值  $\varepsilon_{\text{enter}}$ 。

**定理 1.** 所提死区迟滞切换机制使编队闭环系统满足：由相空间误差与星间距判据触发的切换不产生 Zeno 抖振，其相邻两次切换的时间间隔存在正下界；区域边界引发的唤醒为孤立非累积事件；且卫星驻留误差一致最终有界，稳态收敛域为有界正不变集。

**证.** 相空间误差(18)中， $e_{p,j}$  为卫星至目标区域边界的距离，其关于位置满足 1-Lipschitz 条件，即沿轨迹的变化率满足  $|\dot{e}_{p,j}| \leq \|\dot{r}_j\| \leq v_{\text{max}}$ ，且  $e_{v,j} = \|v_j\|$ ，故其变化率有界：

$$|\dot{\gamma}_j| \leq w_p v_{\text{max}} + w_v (u_{\text{max}} + \bar{a}) \triangleq L_\gamma \quad (22)$$

由 2.3 节迟滞逻辑，休眠的进入要求  $\gamma_j \leq \varepsilon_{\text{enter}}$ ，而经  $\gamma_j > \varepsilon_{\text{exit}}$  退出须使  $\gamma_j$  的净增量不小于迟滞间隙  $\delta = \varepsilon_{\text{exit}} - \varepsilon_{\text{enter}}$ ；反向再入休眠须使  $\gamma_j$  净降不小于  $\delta$ 。结合式(22)，跨越该间隙所需时间不小于  $\delta / L_\gamma$ ，故相空间误差通道上相邻切换的间隔满足：

$$\tau_{\min} \geq \frac{\delta}{L_\gamma} > 0 \quad (23)$$

同理，星间安全间距判据的进入与退出门限之间存在正间隙，即  $d_{\text{safe,in}} - d_{\text{safe,out}} > 0$ ，且星间相对速率有界，这在该通道上给出了类似的时间正下界。因此上述两个判定通道在有限时间内切换次数有限，Zeno 现象被排除。区域边界判据的进入与退出共用同一边界、无迟滞间隙，但休眠仅在卫星位于区域内且低速（速度项已满足门限）时触发，故由此引发的唤醒仅对应卫星缓慢漂出边界的情形；唤醒后控制模态每个决策周期将其净向区域内部驱动，使该类事件相互孤立、不累积，不构成高频切换。综上，切换系统无 Zeno 行为。

在控制模态下，PD 跟踪器在表 1 所列增益下作用于相对动力学式(1)，所构成的标称闭环在推力未饱和条件下，于驻留区域附近局部指数稳定；当输入有界摄动  $\bar{a}$  后，该闭环系统满足输入到状态稳定，卫星的驻留误差将被限制在 1 个半径与  $\bar{a}$  成正比的

残差球内。由前述摄动上界  $\bar{a}$  足够小的设定, 该残差界小于  $\varepsilon_{\text{enter}}$ , 从而保证系统状态最终能收敛至满足  $\gamma_j \leq \varepsilon_{\text{enter}}$  的稳态区域。在休眠模态下, 一旦  $\gamma_j > \varepsilon_{\text{exit}}$  即触发唤醒, 故休眠期间恒有  $\gamma_j \leq \varepsilon_{\text{exit}}$ 。综合两模态, 相空间误差  $\gamma_j$  恒被约束于有界集内, 稳态收敛域为正不变集, 编队驻留误差一致最终有界。证毕。

由式(23)可见, 迟滞间隙  $\delta$  是排除稳态抖振的关键; 若将其退化为单一阈值即  $\delta = 0$ , 将导致理论切换间隔  $\tau_{\min} \rightarrow 0$ , 此时微小的边界扰动便会迫使系统陷入高频振荡。本文取  $\delta = 1.08$ , 是为了保证  $\tau_{\min}$  充分大从而有效抑制抖振, 与防止  $\delta$  过大导致休眠响应滞后之间取得工程折衷, 这也从稳定性角度解释了 2.3 节采用双阈值设计的必要性。

### 3 仿真实验与分析

#### 3.1 仿真场景与训练配置




图 5 仿真场景三维示意图

Fig. 5 Three-dimensional illustration of the simulation scenario

仿真以地球低轨 500 km 高度圆轨道作为参考轨道, 引入含  $J_2$  摄动与大气阻力的非线性相对动力学模型。大气阻力采用参考高度处常值密度模型, 取 500 km 处大气密度  $\rho = 5 \times 10^{-13} \text{ kg/m}^3$ , 参考弹道系数  $B_{\text{ref}} = 0.044 \text{ m}^2/\text{kg}$ , 各卫星弹道系数在  $B_{\text{ref}}$  基础上附加  $\pm 15\%$  随机扰动以模拟个体品质比差异。6 颗同构微小卫星在以目标区域中心为球心、半径 50~75 m 的球壳内随机初始化, 需共同穿越分布于半径 20~45 m 球带内的 5 颗非合作碎片, 最终进入中心  $\pm 5 \text{ m}$  的立方体目标区域。碎片在同一摄动动力学下沿有界轨道运动, 初始相对速度约 5 mm/s。编队成功判据为: 全部卫星连续驻留 30 个决策步且全

程零碰撞。本文以编队成功率作为核心评价指标, 定义为满足该判据的成功回合数占总评估回合数的比例。仿真场景的三维示意如图 5 所示。

SAC 策略网络的 Actor 和 Critic 均采用两层隐藏层、每层 256 个神经元的多层感知机, 激活函数为 ReLU。训练采用余弦衰减学习率调度, 熵目标在前 45% 训练步内固定为 -2.0 以鼓励充分探索, 随后线性收紧至 -4.0 促使策略收敛; 训练时对执行器施加 4% 的推力噪声以提升鲁棒性。PPO 基线组与本文方法采用完全一致的网络结构、奖励函数、仿真环境与折扣因子, 各自特有超参数均按常用推荐值设置以保证对比公平性。其余关键参数的取值见表 1。

表 1 实验超参数

Table 1 Experimental hyperparameters

| 参数                                                        | 数值                 |
|-----------------------------------------------------------|--------------------|
| 学习率 $l_t$                                                 | $2 \times 10^{-4}$ |
| 折扣因子 $\gamma$                                             | 0.995              |
| PD比例增益 $k_p / \text{s}^{-2}$                              | 0.008              |
| PD微分增益 $k_d / \text{s}^{-1}$                              | 0.10               |
| 相空间误差位置系数 $w_p / \text{m}^{-1}$                           | 1.0                |
| 相空间误差速度系数 $w_v / (\text{s} \cdot \text{m}^{-1})$          | 83.3               |
| 死区进入阈值 $\varepsilon_{\text{enter}}$                       | 1.0                |
| 死区退出阈值 $\varepsilon_{\text{exit}}$                        | 2.08               |
| 星间安全间距进入阈值 $d_{\text{safe}}^{\text{in}} / \text{m}$       | 2.0                |
| 星间安全间距退出阈值 $d_{\text{safe}}^{\text{out}} / \text{m}$      | 1.0                |
| 最大推力加速度 $u_{\text{max}} / (\text{m} \cdot \text{s}^{-2})$ | $2 \times 10^{-3}$ |
| 动力学惩罚权重 $w_{\text{dyn}}$                                  | 1.0                |
| 决策周期 $T_{\text{cl}} / \text{s}$                           | 40                 |
| 底层积分步数 $K$                                                | 8                  |
| 总训练步数                                                     | $3 \times 10^6$    |
| 基础负奖励 $r_{\text{base}}$                                   | -1.0               |
| 进度奖励系数 $r_{\text{inc}}$                                   | 1.5                |
| 驻留正奖励 $r_{\text{dwell}}$                                  | 1.0                |
| 终局成功奖励 $r_{\text{success}}$                               | 20.0               |
| 越界碰撞碎片惩罚                                                  | -200               |
| 星间碰撞惩罚                                                    | -150               |

#### 3.2 控制性能和收敛性对比

首先在代表性场景下考察本文方法的控制性能与运动轨迹, 结果如图 6 所示。图 6(a)给出 6 颗卫星的三维运动轨迹, 各星由随机初始位置出发、穿越碎片群后进入中心目标区域, 局部放大显示卫星 6 贴近动态碎片通过时的最小间距为 1.40 m, 裕度



充分。右侧的四联曲线表明，各星位置误差 $e_{p,j}$ 与速度误差 $e_{v,j}$ 平滑收敛至零，归一化推力在进入驻留

后因触发死区而截断为零，全程最近间距 $d_{\min}$ 始终高于 0.5 m 碰撞阈值。




图 6 代表性场景下的运动轨迹与控制性能

Fig. 6 Trajectories and control performance in a representative scenario

随后对比相同仿真设定下 SAC 与 PPO 算法的训练过程。图 7 给出了两组实验的回合奖励与归一化燃料消耗比曲线，归一化燃料消耗比越小，表明任务耗油越低。




图 7 SAC 与 PPO 训练过程对比

Fig. 7 Comparison of training processes between SAC and PPO

图 7(a)显示，SAC 算法在训练约 500k 步时回合奖励已升至正值并趋于平稳，而 PPO 需约 1.5M 步才能收敛。图 7(b)则反映出 SAC 的燃料消耗表现更优，其归一化燃料消耗比最终稳定在 0.37 左右，相比 PPO 的 0.55 降低了约 33%。

上述差异源于 SAC 利用经验回放进行离线更新、样本利用率高，且最大熵正则化在密集碎片环境中更利于探索有效轨迹，离线更新的稳定梯度也使动作更连贯、燃料消耗更低。因此后续实验均采用 SAC 作为基础训练算法。

### 3.3 消融实验与机制验证

为了验证死区迟滞机制和动力学惩罚各自的作用，本文设计了 4 组蒙特卡罗实验，每组评估 100 次。主方案基于 SAC 算法同时启用这两项机制，去除死区消融组仅关闭死区机制，去除惩罚消融组仅去除动力学惩罚，基线组则在主方案的基础上将算法替换为 PPO。各组网络结构与环境参数保持一致。




图 8 主方案与无死区消融组的推力与驻留燃料消耗对比  
Fig. 8 Comparison of thrust and dwell-phase fuel consumption between the proposed method and the no-deadband ablation

图 8 比较了主方案与去除死区消融组的推力与燃料消耗情况。图 8(a)显示，当卫星陆续进入目标区域后，两组推力出现明显分化：主方案触发死区后推力被截断，该场景中驻留期归一化推力均值降至约 0.066；而无死区组的推力则维持在 0.799 左右，体现了连续动作网络存在稳态残余的缺陷。对应图 8(b)的曲线可见，主方案在驻留期的累积燃料消耗几乎停止增长，而无死区组仍呈线性上升，这表明死区机制有效抑制了驻留阶段的燃料浪费。

动力学惩罚的作用集中在趋近阶段，如图 9 所示。图 9(a)对比两组的进场末速度：含惩罚组到达目标区域的平均速度约为 1.4 mm/s，远低于无惩罚组的 9.9 mm/s。低速趋近减小了相空间误差中的速度项，使系统更易满足休眠门限，并直接体现在死区触发延迟上——图 9(b)显示含惩罚组平均约 6 步即进入死区，而无惩罚组因初速度过大，平均需约 22 步减速才能触发。这进而导致图 9(c)中含惩罚组过渡阶段的燃料消耗约为无惩罚组的四分之一。




图 9 动力学惩罚对趋近速度、死区触发延迟与过渡期燃料消耗的影响

Fig. 9 Effects of the dynamic penalty on approach speed, deadband trigger delay, and transition-phase fuel consumption




图 10 4 组方案的蒙特卡罗燃料消耗分布（100 次评估）

Fig. 10 Monte Carlo fuel consumption distributions of four schemes (100 evaluations)

图 10 和表 2 汇总了 100 次蒙特卡罗测试的定量结果。主方案编队成功率为 87%，平均归一化燃料消耗为 0.369，在 4 组中最低，13 次失败均因碰撞导致且无一超时，这反映了在极端碎片走廊环境下，仅依赖局部测距的分布式反应避障控制的物理性能上限。无惩罚组成功率降至 76%、燃料增至 0.437，失败兼含碎片与星间碰撞，源于进场速度偏高导致

避障减速余量不足。无死区组成功率跌至 53%、燃料增至 0.811，驻留期推力抖动引发多达 164 次星间碰撞，表明死区机制除省油外更显著降低了碰撞风险。PPO 基线组成功率仅 48%、燃料 0.841、驻留推力 0.690，整体质量最差。两项机制缺一不可，共同保障了编队的高成功率与低油耗。

表 2 定量结果汇总表

Table 2 Quantitative results summary of ablation experiments

| 方案      | 编队成功率/% | 平均归一化燃料 | 驻留推力均值 |
|---------|---------|---------|--------|
| 主方案     | 87      | 0.369   | 0.066  |
| 去除死区消融组 | 53      | 0.811   | 0.799  |
| 去除惩罚消融组 | 76      | 0.437   | 0.139  |
| PPO 基线组 | 48      | 0.841   | 0.690  |

### 3.4 与传统模型预测控制方法对比

为评估本文方法相对传统优化类方法的性能，本节以模型预测控制（MPC）作为对比基线。在每个控制周期，MPC 基于离散相对动力学在线求解如下滚动优化问题<sup>[7]</sup>：

$$\begin{aligned}
 \min_{\{u_k\}} & \sum_{k=0}^{N-1} \left( \|p_k - p_{\text{tar}}\|_Q^2 + \|u_k\|_R^2 \right) \\
 \text{s.t.} \quad & x_{k+1} = Ax_k + Bu_k \\
 & \|u_k\| \leq u_{\text{max}} \\
 & \|p_k - p_{\text{obs},j}\| \geq d_{\text{safe}}
 \end{aligned} \quad (24)$$

式中： $x_k$  为第  $k$  步的相对状态矢量； $u_k$  为控制输入矢量； $p_k$  为第  $k$  步的位置矢量； $p_{\text{tar}}$  为目标区域中心； $p_{\text{obs},j}$  为第  $j$  个碎片位置； $Q, R$  为权重矩阵； $A, B$  为系统状态转移矩阵与输入矩阵；推力饱和上限  $u_{\text{max}}$  与安全间距阈值  $d_{\text{safe}}$  均取与本文一致的值，预测时域与本文决策周期相协调。求解后仅执行首步控制并滚动重解。为区分信息完备度与部署条件的影响，设置两个版本：1) 集中式 MPC，可获取全编队与全碎片的完整状态联合求解，代表理想性能上限；2) 分布式 MPC，采用与本文一致的无通信架构，各星仅依据自身局部观测状态独立求解。两者均在相同的真实环境与冻结测试库下运行，结果如表 3 所示。

由表 3 可见，3 者构成清晰的性能阶梯。集中式 MPC 以全局信息取得 96% 的最高成功率，但算力约

为本文 60 倍且依赖集中决策节点，仅为不可部署的性能上界。分布式 MPC 与本文同为无通信架构且拥有完整碎片状态，成功率却低至 79%，其 21 次失败中 19 次为超时——缺乏通信导致将邻星视为静态障碍保守避让、难以协调穿越；本文无一超时，13 次失败均为最坏碎片走廊下的碰撞，最小间距仍达 1.33 m。两版 MPC 成功回合燃料消耗略低于本文，源于全状态信息下的保守低速策略，但综合成功率、算力与可部署性，本文在极低信息约束下取得了更优的性能。

表 3 本文方法与 MPC 基线的对比

Table 3 Comparison between the proposed method and MPC baselines

| 方案     | 编队成功率/% | 平均归一化燃料 | 单步在线算力/ms |
|--------|---------|---------|-----------|
| 集中式MPC | 96      | 0.257   | 23.0      |
| 本文方法   | 87      | 0.369   | 0.37      |
| 分布式MPC | 79      | 0.267   | 2.2       |

### 3.5 策略泛化性验证

分布式参数共享架构允许将单一训练策略零样本迁移至不同场景。本节以 6 星、 $\pm 5$  m 区域、4% 执行噪声、5 颗碎片的训练设定为基准，从集群规模、目标区域尺寸、执行噪声与碎片数量 4 个维度进行零样本泛化测试。各档独立评估 100 次，泛化成功率定义为满足编队成功判据的回合数占该档评估回合数的比例，结果如图 11 所示；基准设定下成功率为 88%，与主方案的 87% 基本一致。

集群规模方面，4 星升至 94%、8 星降至 72%，后者因卫星数增加使区内密度上升、避撞机动增多导致，但仍验证了分布式决策规则不受集群规模限制的优势。目标区域方面， $\pm 7$  m 宽松区域为 86%、与基准相当， $\pm 4$  m 紧凑区域降至 82%——6 颗卫星在该空间内平均间距约 3.2 m，易触发安全间距而引发持续避撞，实际应用中可通过在线微调安全门限缓解。执行噪声方面，噪声由 4% 提升至 8% 后成功率降至 79%，仍保持有效编队能力，表明策略对执行器不确定性具有良好的鲁棒性。碎片数量方面，减至 3 颗时成功率升至 90%，增至 8 颗时则降至 79%，体现了策略对障碍密度的适应能力。综上，4 个维度的成功率均落在 72%~94% 区间，随条件偏离

基准平滑退化、未现骤降，验证了所学策略良好的零样本泛化能力。




图 11 策略在非训练场景下的零样本泛化测试结果

Fig. 11 Zero-shot generalization test results of the policy under non-training scenarios




图 12 碎片初始相对速度扫描下的无碰撞率与最小间距

Fig. 12 Zero-collision rate and minimum separation under debris initial relative velocity sweep

为进一步评估对碎片相对运动速度不确定性的鲁棒性，将碎片初始相对速度由 5 mm/s 逐步增至 50 mm/s 进行零样本应力测试，结果如图 12 所示。在 5/10/20/50 mm/s 下无碰撞率分别为 96/98/97/86%，平均最小星-碎片间距由 11.7 m 降至 3.7 m，始终远高于 0.5 m 碰撞阈值；即便初速达 50 mm/s，无碰撞率仍维持 86%，与主方案相当，表明策略对碎片动态速度具有良好鲁棒性。

## 4 结论

针对低轨强摄动与空间碎片密集环境下的卫星编队控制问题，本文提出一种引入死区迟滞的分布式深度强化学习避障控制方法。主要结论如下：

设计的相空间死区迟滞机制在卫星进入稳态收

敛域后物理截断推力并暂停网络推理,将驻留期推力均值由 0.799 大幅降至 0.066,并从理论上证明了该切换机制的无 Zeno 特性与闭环误差的一致最终有界性。该机制与动力学惩罚协同作用,有效克服了连续动作策略在驻留阶段的残余推力缺陷,显著降低了全任务周期的燃料消耗。与传统模型预测控制的对比表明,本文方法在无星间通信、仅依赖局部测距的约束下取得了优于同类方法的综合性能。完全分布式的 SAC 参数共享架构赋予了策略优异的泛化能力:在 100 次蒙特卡罗评估中编队成功率达 87%,所学策略可零样本迁移至不同集群规模、目标区域、执行噪声与碎片数量等复杂条件,泛化成功率保持在 72%以上。

未来可进一步探索该方法在航天器六自由度相对位姿耦合控制等更为复杂的空间任务中的应用拓展。

## 参 考 文 献

- [1] Zhang Jingrui, Cai Yifan, Xue Chenbao, et al. LEO mega constellations: review of development, impact, surveillance, and governance[J]. *Space: Science & Technology*, 2022, 2022: 9865174.
- [2] Xue Zhihui, Liu Jinguo, Wu Chenchun, et al. Review of in-space assembly technologies[J]. *Chinese Journal of Aeronautics*, 2021, 34(11): 21-47.
- [3] Wang Yu, Liu Kang, Chen Peiyin, et al. Robust adaptive fault-tolerant control for the approach phase of space debris removal mission : a finite-time input-to-state stability scheme[J]. *Advances in Space Research*, 2025, 75(7): 5886-5898.
- [4] BURNS R, MCLAUGHLIN C A, LEITNER J, et al. TechSat 21 : formation design , control , and simulation[C]//IEEE Aerospace Conference Proceedings. Big Sky, MT, USA: IEEE, 2000: 19-25.
- [5] ROTH N H, JOHNSTON-LEMKE B, DAMAREN C J, et al. Formation and attitude control for the CanX-4 and CanX-5 formation flying mission[C]//Proceedings of the 18th IFAC World Congress. Milano, Italy: IFAC, 2011: 3033-3038.
- [6] BANDYOPADHYAYS, FOUST R, SUBRAMANIAN G P, et al. Review of formation flying and constellation missions using nanosatellites[J]. *Journal of Spacecraft and Rockets*, 2016, 53(3): 567-578.
- [7] MORGAN D, CHUNG S J, HADAEGH F Y. Model predictive control of swarms of spacecraft using sequential convex programming[J]. *Journal of Guidance, Control, and Dynamics*, 2014, 37(6): 1725-1740.
- [8] BASU H, PEDARI Y, ALMASSALKHI M, et al. Computationally efficient collision-free trajectory planning of satellite swarms under unmodeled orbital perturbations[J]. *Journal of Guidance, Control, and Dynamics*, 2023, 46(8): 1548-1563.
- [9] BASHNICK C, ULRICH S. Fast model predictive control for spacecraft rendezvous and docking with obstacle avoidance[J]. *Journal of Guidance, Control, and Dynamics*, 2023, 46(5): 998-1007.
- [10] Wang Yu, Liu Kang, Chen Yuquan. Neuroadaptive predefined-time 6-DOF integrated tracking control for spacecraft proximity operations with pose constraints[J]. *Advances in Space Research*, 2026, 77: 3906-3921.
- [11] TIPALDI M, IERVOLINO R, MASSENIO P R, et al. Reinforcement learning in spacecraft control applications: advances, prospects, and challenges[J]. *Annual Reviews in Control*, 2022, 54: 1-23.
- [12] HOVELL K, ULRICH S. Deep reinforcement learning for spacecraft proximity operations guidance[J]. *Journal of Spacecraft and Rockets*, 2021, 58(2): 254-264.
- [13] TAFANIDIS N A, BANERJEE A, SATPUTE S, et al. Reinforcement learning-based station keeping using relative orbital elements[J]. *Advances in Space Research*, 2025, 76: 750-763.
- [14] Mu Chaoxu, Liu Shuo, Lu Ming, et al. Autonomous spacecraft collision avoidance with a variable number of space debris based on safe reinforcement learning[J]. *Aerospace Science and Technology*, 2024, 149: 109131.
- [15] Qu Qingyu, Liu Kexin, Wang Wei, et al. Spacecraft proximity maneuvering and rendezvous with collision avoidance based on reinforcement learning[J]. *IEEE Transactions on Aerospace and Electronic Systems*, 2022, 58(6): 5823-5834.
- [16] 徐龙威, 邱实, 曹喜滨. 基于强化学习的燃料最优卫星编队重构控制方法[J]. *宇航学报*, 2026, 47(3): 623-633.
- Xu Longwei, Qiu Shi, Cao Xibin. Fuel-optimal satellite formation reconfiguration control method based on

- reinforcement learning[J]. *Journal of Astronautics*, 2026, 47(3): 623-633.
- [17] Sun Jun, Meng Yizhen, Huang Jing, et al. Distributed cooperative control with collision avoidance for spacecraft swarm reconfiguration via reinforcement learning[J]. *Acta Astronautica*, 2023, 205: 95-109.
- [18] 金伟成, 陈提, 胡海岩. 含动力学奖励的航天器编队深度强化学习控制[J]. *自动化学报*, 2025, 51(10): 2283-2292.
- Jin Weicheng, Chen Ti, Hu Haiyan. Deep reinforcement learning control for spacecraft formation with dynamic reward[J]. *Acta Automatica Sinica*, 2025, 51(10): 2283-2292.
- [19] Jin Weicheng, Chen Ti, Wei Zhengtao, et al. Deep reinforcement learning for distributed spacecraft formation control enhanced by SE(3) dynamics[J]. *Aerospace Science and Technology*, 2026, 175: 111967.
- [20] MYSORE S, MABSOUT B, MANCUSO R, et al. Regularizing action policies for smooth control with reinforcement learning[C]//*Proceedings of the 2021 IEEE International Conference on Robotics and Automation*. Xi'an, China: IEEE, 2021: 1810-1816.
- [21] TABORDAP, MATIAS H, SILVESTRE D, et al. Convex MPC and thrust allocation with deadband for spacecraft rendezvous[J]. *IEEE Control Systems Letters*, 2024, 8: 1132-1137.
- [22] WILLIAMS K R, SCHLOSSMAN R, WHITTEN D, et al. Trajectory planning with deep reinforcement learning in high-level action spaces[J]. *IEEE Transactions on Aerospace and Electronic Systems*, 2023, 59(3): 2513-2529.
- [23] CLOHESSY W H, WILTSHIRE R S. Terminal guidance system for satellite rendezvous[J]. *Journal of the Aerospace Sciences*, 1960, 27(9): 653-658.
- [24] GAIAS G, ARDAENS J S, MONTENBRUCK O. Model of J2 perturbed satellite relative motion with time-varying differential drag[J]. *Celestial Mechanics and Dynamical Astronomy*, 2015, 123(4): 411-433.
- [25] SUTTON R S, BARTO A G. Reinforcement learning: an introduction[M]. 2nd ed. Cambridge, MA, USA: MIT Press, 2018.
- [26] HAARNOJA T, ZHOU A, ABBEEL P, et al. Soft actor-critic: off-policy maximum entropy deep reinforcement learning with a stochastic actor[C]//*Proceedings of the 35th International Conference on Machine Learning*. Stockholm, Sweden: PMLR, 2018: 1861-1870.
- [27] Li Zhanjie, Ma Yajing, Yue Dong, et al. Guaranteed dwell-times of hysteresis switching for switched nonlinear systems via switching characteristic indices[J]. *SIAM Journal on Control and Optimization*, 2023, 61(3): 1610-1630.

作者简介:

**王 昱** (1991-), 男, 博士, 副教授, 主要从事航天器控制、无人系统协同控制、雷达系统工程等方面的研究。

电话: 18362961020

E-mail: andyyu@hhu.edu.cn

**王荣辉** (2003-), 男, 硕士生, 主要从事低轨卫星编队飞行控制、深度强化学习等方面的研究。

电话: 15632801233

E-mail: 15632801233@163.com

**蔡 旭** (1994-), 男, 博士, 讲师, 主要从事线性系统理论、混杂动力学控制及机器人控制等方面的研究。本文通信作者。

电话: 18861821805

E-mail: caixu@hhu.edu.cn